Classification supervisée sémantique d'articles de presse en français

Samuel Gesche¹, Elöd Egyed-Zsigmond¹, Sylvie Calabretto¹, Guy Caplat², Jean Beney²

¹ Université de Lyon, CNRS, INSA-Lyon, LIRIS, UMR5205, F-69621, France 20, avenue Albert Einstein, 69621 Villeurbanne Cedex prenom.nom@insa-lyon.fr

² INSA-Lyon, LCI, F-69621, France 20, avenue Albert Einstein 69621 Villeurbanne Cedex prenom.nom@insa-lyon.fr

Résumé. La classification supervisée est un champ de recherche fertile, qui ne dispose pas encore d'une théorie figée. Elle se nourrit donc régulièrement d'avancées dans d'autres domaines. Nous présentons ici nos récentes expériences en classification supervisée de textes courts de presse francophone. Ces expériences tirent parti des bases sémantiques généralistes de grande taille qui ont été récemment mises en place dans le cadre du Web sémantique. Nous effectuons un enrichissement sémantique de nos documents afin de pallier à leur petite taille qui rend les approches classiques inefficaces. L'utilisation de ressources multilingues nous permet de tirer partie des ressources disponibles en anglais.

Mots-clés: classification supervisée, enrichissement sémantique, textes courts

Abstract. Supervised document classification is a research field where a unified theory has yet to be found. Therefore, advances in other fields can often be used in order to get better results in some case or another. In this context, we present our latest experiences with largescale semantic databases. We use these to semantically enrich small French texts for which statistical methods show a poor performance. Besides, the use of multilingual resources allows us to circumvent the fact that most resources are in English language.

Keywords: supervised classification, semantic enrichment, small texts

1 Introduction

La classification supervisée de documents est un champ de recherches ancien, mais toujours actif : il n'existe pas encore de théorie unifiée permettant de définir l'algorithme optimal pour ranger des documents dans les classes suivant une problématique donnée. Cependant, de nombreuses et diverses approches sont disponibles, de l'optimisation par interface du rangement manuel aux algorithmes par apprentissage et au traitement automatique de la langue.

Les avancées récentes du Web Sémantique ont par ailleurs conduit à la compilation de grandes bases de données, souvent structurées sous formes d'ontologie. Or ces bases de données sont désormais multilingues, et peuvent être utilisées sur des matériaux en français là où la plupart des bases classiques sont limitées à l'anglais. Cela nous a amené à explorer l'utilisation de ces ressources comme catalyseurs d'une classification supervisée. Plus précisément, nous partons de documents de petite taille en français (titre et résumé de quelques dizaines de mots), à ranger dans des classes décrites de manière similaire (étiquette et descriptif); nous utilisons donc ces ressources sémantiques pour enrichir le contenu de ces documents et exemples afin de pouvoir raisonnablement escompter des recoupements.

Nous présenterons donc ici une approche de classification supervisée par enrichissement sémantique. Nous commencerons par présenter le contexte de notre recherche. Ensuite, nous présenterons le concept de nuage pondéré de lemmes, qui forme le centre de notre approche, ainsi que le processus d'enrichissement sémantique qui permet de les constituer. Enfin, nous présenterons nos premiers résultats, avant donner nos conclusions sur cette étude.

2. Contexte

2.1 Le projet IPRI

16 Conseil Supérieur de l'Audiovisuel

Le projet IPRI¹⁵, auquel nous apportons notre contribution en tant que chercheurs en informatique, a pour objectif l'analyse du pluralisme et de la redondance dans la presse en ligne.

En effet, il existe des initiatives nationales en France qui garantissent le pluralisme de la presse écrite (comme le contrôle du temps de parole par le CSA¹⁶), mais rien n'existe de comparable pour la presse en ligne. La position officielle est

¹⁵ Internet : Pluralisme et Redondance de l'Information, projet ANR jeunes chercheuses et jeunes chercheurs de 2009 à 2012, site web hébergé sur http://liris.cnrs.fr/IPRI

que l'Internet est un lieu naturel de pluralisme ([1], [2]). Cependant, il s'agit aussi d'un lieu naturel de copie [3], et pas seulement en ce qui concerne les œuvres artistiques. Cette dernière thèse est renforcée par des études qualitatives qui ont pointé vers un risque de redondance du fait du métier de rédacteur Web [4]. Afin de comprendre le phénomène, nous menons actuellement une étude complète, et notamment avec un volet quantitatif pour donner du poids aux analyses plus qualitatives.

A cette fin, il nous est nécessaire, en tant que partenaires informaticiens, de fournir les outils d'analyse quantitative et qualitative nécessaires à cette étude. Nous avons donc mis en place un mécanisme de collecte d'un échantillon à peu près exhaustif de la production éditoriale d'actualités générales et politiques ¹⁷ sur Internet, échantillon défini par nos partenaires en Communication ¹⁸. Nous travaillons désormais à la structuration de cette collection, qui est une étape nécessaire. Cette structuration passe par une classification des articles au sein de thématiques.

2.2 Positionnement

L'étude de la presse en ligne est devenue ces derniers temps un enjeu de recherche phénoménal. En effet, les agrégateurs classiques laissent de côté beaucoup de problématiques, à commencer par la fouille de données. L'enjeu est réel, puisqu'il consiste à créer la consommation journalistique de demain. En effet, les agrégateurs ont déjà amené un effacement progressif du concept de média au profit de celui de sujet. Il est donc important pour les médias qui veulent conserver leur visibilité d'offrir un service supplémentaire à celui de l'actualité (et la visite des archives est un bon départ), et pour les futurs remplaçants des agrégateurs d'offrir ce que voudra l'internaute de demain. Ainsi, on peut voir aujourd'hui un certain nombre de projets basés sur l'utilisation de ressources sémantiques pour la fouille de corpus d'archives comme ceux de l'AFP [5], la BBC [6] ou le New York Times [7]. Parallèlement, des initiatives telles que MediaCloud¹⁹ ou des entreprises comme Linkfluence [8] proposent une approche transversale, multi-sites, mais centrée plus particulièrement sur l'actualité. L'INA ayant obtenu le dépôt légal du Web en France, leurs équipes de recherche travaillent elles aussi sur la question de la structuration d'un tel corpus.

Notre approche est plus modeste : nous ne comptons pas offrir à l'internaute de demain l'actualité, mais offrir des réponses fiables à la question du pluralisme. Nous ne voulons pas explorer en profondeur un média donné, mais acquérir une vision exhaustive de l'offre –et de la consommation, mais c'est un autre sujet–

¹⁷ Cette catégorie, qui correspond à une labellisation officielle, est le principal champ d'investigation des études concernant le pluralisme.

¹⁸ Notamment, les laboratoires ELICO de l'Université de Lyon et LERASS de Toulouse.

¹⁹ http://www.mediacloud.org/

d'information. De ce fait, nous nous concentrons sur l'acquisition de la publication de l'ensemble des sites d'information générale et politique, mais nous ne pouvons nous offrir ni l'accès à toutes les bases de données, ni un nombre inconsidéré de partenariats. Nous travaillons donc à une troisième alternative, celle de tirer le maximum de ce qui est disponible directement du le Web -et donc à l'internaute. Nous avons donc des textes courts issus des flux RSS, des articles sous forme HTML pour lesquels l'hétérogénéité structurelle est la règle. Nous exposons ici comment nous traitons l'information de ces flux RSS.

3 Approche

L'enrichissement sémantique implique trois entités différentes :

- Les articles sous forme d'entrées RSS;
- La taxonomie selon laquelle classer ces articles;
- Les ressources sémantiques qui permettent d'effectuer la classification.

L'approche en elle-même consiste à prendre les textes courts de part et d'autre (ceux des articles et ceux de la taxonomie) et à les enrichir pour former ce que nous appelons des nuages pondérés de lemmes (figure 1). Le degré d'appartenance d'un article à une thématique de la taxonomie est ensuite calculé à partir de l'intersection de ces nuages, par analyse vectorielle.

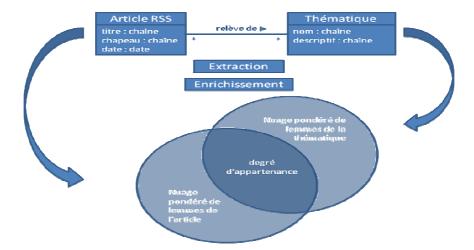


Figure 1. Schéma général du procédé de classification par enrichissement sémantique

3.1 Lemmatisation

Puisque nous manipulons, dans les trois entités, des termes au sein de textes construits, nous avons pris le parti d'effectuer une lemmatisation et un étiquetage lexical de ces termes. Cela nous permet d'effectuer une comparaison des termes sans devoir recourir à une analyse de similarité coûteuse en termes de temps. La lemmatisation est effectuée à la collecte pour les articles, et une fois pour toutes en ce qui concerne la taxonomie et les ressources sémantiques.

La lemmatisation diminue grandement le nombre de mots que nous avons à manipuler tout en n'introduisant que peu de bruit (les ambiguïtés, polysémies et homonymies). L'étiquetage lexical des termes nous permet de nous focaliser, en plus de cela, sur certaines natures de mots (par exemple les noms), ce qui réduit d'autant plus la charge.

Puisque nous n'effectuons nos calculs de catégorisation que sur des formes lemmatisées et étiquetées, dans la suite de notre propos, nous parlerons de *lemmes* et non plus de *termes*.

Notre approche se fonde sur la provenance des lemmes et sur leur nature. Nous faisons abstraction de tout lien que des lemmes pourraient avoir entre eux (par exemple, faire partie d'un même texte, ou être en succession l'un de l'autre). Nous bâtissons donc, à mesure que l'enrichissement progresse, des ensembles, ou nuages, de lemmes.

Un article ou une thématique est de ce fait décrite par un nuage contenant non seulement ses lemmes propres, mais également les lemmes obtenus par enrichissement.

3.2 Enrichissement

La présence de ressources sémantiques colossales est une donne relativement récente dans le monde de la recherche. En effet, depuis quelques années, nous assistons à la concrétisation du Web Sémantique par la constitution de gigantesques ressources. Cela fait longtemps qu'existent des ressources de petite taille, comme des ontologies de domaine ; en revanche, la récupération toujours plus exhaustive de l'encyclopédie Wikipedia [9] au sein de bases sémantiques généralistes comme DBPedia [10] et Yago ([11], [12]) forme une grande avancée. Ces ressources peuvent être interrogées en ligne (pour des usages modérés) ou téléchargées sous forme de bases de triplets (pour une utilisation intensive).

L'intérêt majeur de ces bases, dans notre cas, est qu'elles indexent une encyclopédie multilingue et sont donc, par essence, multilingues. Elles nous permettent donc de nous affranchir de la problématique de la traduction. Par ailleurs,

Nous avons testé quatre procédés d'enrichissement sémantique différents à partir de ces ressources sémantiques.

Enrichissement par généralisation. Les taxonomies, même quand elles ont un descriptif, utilisent des termes généraux, alors que les articles utilisent des termes spécifiques de la problématique traitée. Ainsi, l'actualité parlera de « *Michaël Jackson* » ou de « *fuite de produit chimique toxique* » tandis que la taxonomie disposera des étiquettes « *Rock* » et « *Accident industriel* ».

L'idée est donc, puisque les ontologies commencent à fleurir sur Internet, et en particulier celles qui sont liées aux préoccupations des internautes, de remonter dans l'ontologie jusqu'à trouver le concept optimal pour le classement.

DBPedia, par exemple, fournit non seulement un ensemble colossal de concepts tirés des pages Wikipedia, mais les organise en plus au sein d'une ontologie. Cependant, cette ontologie est encore embryonnaire et orientée principalement sur les personnes, les lieux et les œuvres artistiques, qui sont les préoccupations majeures du Web Sémantique. Cette approche est donc peu efficace avec la base DBpedia elle-même.

Enrichissement par catégorisation. Une deuxième manière d'effectuer l'enrichissement de lemmes, si l'on trouve un concept dans une ressource sémantique tirée de Wikipedia, consiste à utiliser le réseau de catégories que fournit l'encyclopédie. En effet, dans un certain nombre de cas, les pages Wikipedia ont été regroupées au sein de listes thématiques. Par exemple, on pourra relier une œuvre artistique à la liste des œuvres de son auteur, de son année, de son mouvement artistique, et ce ne sont que quelques exemples. Toutes ces données peuvent être adjointes aux données initialement contenues dans le texte.

Enrichissement par spécialisation. De manière symétrique, dès lors que les catégories thématiques de la taxonomie sont suffisamment étoffées, nous pouvons décider de rester aux thématiques générales (politique, économie, société, sport etc.) au lieu de chercher la thématique précise. Dans ce contexte, il est intéressant d'enrichir ces thématiques générales par le contenu sémantique additionnel des sous-thématiques. Ainsi, le champ du sport, par exemple, contiendra le nom de tous les sports médiatiques.

Dans ce cas, il est important de tenir compte des disparités d'enrichissement. Supposons en effet, comme c'est le cas dans la taxonomie de l'IPTC, que le domaine du sport contienne quelques dizaines de sous-thématiques, alors qu'un autre domaine, comme les faits divers, n'en contiennent que quelques unes. Beaucoup d'articles relevant du fait divers risquent d'être catégorisés comme sport,

²⁰ Cependant, le coût de la lemmatisation de ces bases limite quelque peu l'intérêt de mises à jour fréquentes.

à cause du seul nombre des termes sportifs qui peuvent s'y trouver. Cette préoccupation diminue fortement en cas de multi-classification.

Enrichissement par champ sémantique. Cette dernière méthode consiste à utiliser la ressource sémantique comme un vecteur de champ sémantique. On retrouve ici une approche qui est déjà utilisée avec des réseaux de termes comme WordNet [13]. L'idée est, une fois que l'on a pu lier un terme du texte à un concept de la ressource, d'utiliser les termes propres de la ressource en renfort.

En particulier, quand à la ressource est adjointe une définition, nous avons presque invariablement une généralisation et une différenciation.

Dans le cas de ressources structurées (comme une base lexicale, un thésaurus voire une ontologie), il est possible de pondérer ce champ sémantique en fonction d'une distance sémantique. Cependant, dans notre cas, le champ sémantique est constitué d'un texte non structuré.

3.3 Pondération

Au final, en combinant ces méthodes d'enrichissement, nous allons nous retrouver avec des « nuages 21 » de lemmes gravitant autour des articles et des thématiques.

Tous ces lemmes n'ont pas le même poids. Certains sont présents directement dans le titre ; d'autres font partie du champ sémantique du chapeau ; d'autres encore sont le fruit d'une généralisation. Il y a des noms, des adjectifs, des verbes et des articles. Certains mots sont présents une fois, d'autres reviennent à plusieurs endroits. Toutes ces informations sont exprimées sous la forme de poids.

Nous avons opté pour une pondération multiplicative : un lemme aura un certain nombre de caractéristiques (mode d'accès, nature et nombre d'occurrences). Ces caractéristiques seront traduites en coefficients. Le poids du lemme sera le produit de ces coefficients.

Mode d'accès au lemme	Coefficient
Lemme du titre	1.0
Lemme de la description	0.75
Opération de généralisation	0.5
Opération de recherche des catégories	0.5
Opération de récupération du champ sémantique	0.33

Tableau 1. Exemple de coefficients attachés au mode d'accès

²¹ Sans relation aucune avec l'artefact de visualisation, le 'nuage de mot'.

Nature du lemme	Coefficient
Nom commun	1.0
Nom propre	1.0
Verbe	0.5
Adverbe	0.0
Adjectif	0.5

Tableau 2. Exemple de coefficients attachés à la nature des lemmes

Les tableaux 1 et 2 présentent des exemples de coefficients. Pour prendre un exemple, supposons que nous obtenions un lemme en généralisant un terme du champ sémantique de l'un des lemmes du titre d'un article : le coefficient attaché à son mode d'accès sera, selon le tableau 1, de 1.0*0.33*0.5, soit 0.17. Il aura donc un poids six fois moindre que le lemme du titre lui-même dans le nuage.

4 Premières expériences

4.1 Ressources

Notre objectif est de classifier des articles de presse généralistes tirés de flux RSS (donc des textes courts comprenant un titre et une description) au sein de la taxonomie généraliste élaborée par l'IPTC (donc des classes comprenant une étiquette et une description). Pour effectuer l'enrichissement sémantique, nous utilisons la ressource multilingue DBPedia, proposant à la fois :

- l'encapsulation des pages Wikipedia, dans toutes les langues disponibles, au sein de concepts translingues étiquetés par une URI;
- une ontologie minimale en OWL, comprenant environ 200 concepts, à laquelle sont liés ces concepts;
- l'ensemble des catégories de Wikipedia regroupant les pages par thème (ainsi, les concepts-pages de DBPedia sont liés à des concepts-catégories);
- le titre et un court résumé en Français d'environ 500000 pages (contre plus de 1,2 millions en anglais).

La mise en relation de ces différentes ressources se fait de la manière suivante :

Entre les nuages pondérés de lemmes des articles et des thématiques (comprenant les lemmes originaux auxquels ont été rajoutés les lemmes issus de l'enrichissement sémantique), la mise en relation se fait par identité : la lemmatisation est censée nous affranchir des contraintes de recherche de similarité ; deux lemmes représentés par la même chaîne de caractère, et ayant la même nature lexicale, sont identiques ; deux lemmes présentant une différence d'un côté ou de l'autre sont différents.

Entre un lemme et un concept de DBPedia, la question est moins immédiate : le rapprochement est effectué par minimisation de la distance d'édition entre le lemme et le titre lié au concept. Plus précisément, nous utilisons l'algorithme suivant : pour un lemme L donné, nous cherchons tous les concepts contenant un lemme représenté par la même chaîne de caractère dans leur titre ; parmi ces concepts, nous choisissons celui dont la distance d'édition entre le titre et la chaîne de caractères représentant le lemme L est minimale.

4.2 Résultats

Nous avons mené des expériences sur un échantillon de 200 articles triés à la main, à catégoriser selon la taxonomie de l'IPTC. Nous n'avons pas enrichi la taxonomie à l'aide d'exemples (cela sera fait dans de prochaines expériences).

Notre première expérience a consisté à tester le nombre de lemmes que pouvait nous fournir le champ sémantique des lemmes des thématiques de plus haut niveau de la taxonomie IPTC. Les résultats sont présentés dans la figure 2.

Comme nous pouvons le voir, l'enrichissement est relativement conséquent, autour de 20 à 30 fois le nombre de lemmes initial, à l'exception d'une thématique qui n'obtient que 13 fois ce nombre. Les résultats sont similaires en ce qui concerne les articles.

Par ailleurs, la distance de similarité (la distance d'édition) donne une excellente performance, d'autant meilleure bien sûr qu'il y a beaucoup de pages Wikipedia candidates pour un lemme.

En revanche, l'étude de l'ontologie, comme nous l'avions pressenti, donne peu de résultats, et ces résultats sont généralement toujours les mêmes. Les catégories, de même, regroupent le même type d'informations que l'ontologie (lieux, personnes et œuvres) et donne des résultats similaires. La plupart des lemmes ne sont tout simplement pas enrichis.

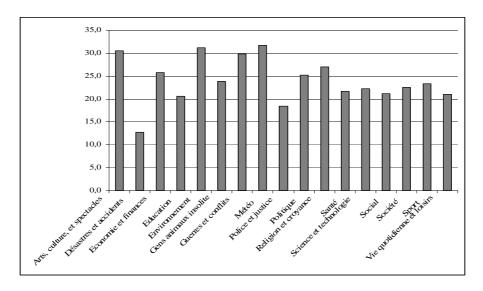


Figure 2. Impact de l'enrichissement sémantique des thématiques de l'IPTC (en abscisse : les différentes thématiques IPTC ; en ordonnées : le facteur d'accroissement du nombre de lemmes

Une tentative de catégorisation sans aucun enrichissement donne un résultat de l'ordre de 10% de pertinence (très peu de lemmes sont communs entre les articles et les classes) sans utiliser d'exemples. L'utilisation de l'ontologie et des catégories reste pauvre (aucun gain en performance notable n'est obtenu). En revanche, la spécialisation des thématiques par les sous-thématiques, ainsi que l'utilisation du champ sémantique, donnent des résultats meilleurs (bien que toujours limités en ce qui concerne le problème lui-même de classification). Le tableau 3 résume ces résultats. L'impact de la pondération n'est pas significative dans les expériences que nous avons faites jusqu'ici.

Procédé employé	Pertinence
Aucun	10%
Spécialisation	17%
Généralisation	10%
Catégorisation	10%
Champ sémantique	17%

Tableau 3. Présentation des résultats suivant la méthode d'enrichissement

4.3 Discussion

Contrairement à ce que nous avions espéré, l'enrichissement sémantique ne permet pas de se passer des exemples, et donc d'une classification préliminaire à la main d'une partie du corpus.

Nous n'avons pas pu étudier la pondération de manière satisfaisante. Nos premières expériences n'ont pas montré d'influence mesurable, cependant il est probable que la médiocrité des résultats impacte ce paramètre.

La question du temps réel n'était pas centrale dans nos expériences, mais elle l'est dans notre problématique. L'accès au champ sémantique d'un lemme se fait en 10 secondes environ. Cela nous amène à des temps de calculs de plusieurs minutes par article; le temps souhaitable est de l'ordre de la seconde, voire moins (nous avons 2500 articles par jour).

Le caractère multilingue (surtout français/anglais) de notre approche est en revanche un réel apport. Nous sommes en mesure d'enrichir les textes français avec des lemmes indifféremment français et anglais en utilisant les concepts comme pivots, ce qui nous aidera à mesure que nous intégrerons d'autres ressources sémantiques.

5 Conclusion

Nous avons présenté notre méthode d'enrichissement sémantique, et nous l'avons appliqué au cas de textes courts, pour lesquels les méthodes classiques sont moins efficaces. Nous avons noté, en l'absence d'exemples, un apport dans deux cas : l'utilisation de ressources sémantiques dédiées au corpus (comme les sousthématiques de la taxonomie IPTC sont dédiées à leurs thématiques respectives), et l'utilisation du champ sémantique d'une ressource généraliste, entendu comme un ensemble textuel tenant lieu de définition. En revanche, nous n'avons pas noté d'amélioration lors de l'emploi de ressources sémantiques spécialisées dans peu de domaines (même lorsque ces domaines sont pertinents mais non exhaustifs, comme les lieux, personnes et œuvres dans notre cas).

Le coût temporel de l'enrichissement sémantique, qui plus est, n'est pas négligeable dans le coût total de la classification. Cela n'est pas forcément rédhibitoire dans le cas d'expériences ponctuelles ; cependant, la classification en temps réel des articles collectés n'est pas envisageable de cette manière.

Afin de parfaire notre analyse, il nous reste à combiner plusieurs de ces approches entre elles, et à les utiliser en présence d'exemples.

6 Bibliographie

- Lancelot A., Les problèmes de concentration dans le domaine des médias, Rapport pour le Premier ministre, 2005.
- Tessier M., Baffert M., La presse au défi du numérique, Rapport pour le Ministre de la culture et de la communication, 2007.
- 3. Olivennes D., Le développement et la protection des œuvres culturelles sur les nouveaux réseaux, Rapport au ministre de la Culture, 2007.
- Rebillard F., « Du traitement de l'information à son retraitement. La publication de l'information journalistique sur l'internet », Réseaux, n°137, 2006, p. 29-68.
- Troncy R., « Explorer des actualités multimédia dans le Web de Données », Actes des 10èmes journées Ingéniérie des Connaissances IC'2009, Hammamet, Tunisie, 25-29 mai 2009, p. 181-192
- Kobilarov G., Scott T., Raimond Y., Oliver S., Sizemore C., Smethurst M., Bizer C., LeeMedia R., « Media meets Semantic Web - How the BBC uses DBpedia and Linked Data to make Connections », In European Semantic Web Conference, Heraklion, Grèce, 31 mai-4 juin 2009.
- 7. Bizer C., The Emerging Web of Linked Data, IEEE Intelligent Systems, vol. 24, n° 5, 2009, p. 87-92.
- 8. Fouetillou G., Jacomy M., Pfaender F., « Two visions of the Web: from globality to locality », In. 2nd IEEE International Conference on Information and Communication Technologies ICTTA '06, Damas, Syrie, 24 28 avril 2006.
- Wu F., Weld D., « Autonomously Semantifying Wikipedia », In 16th Conference on Information and Knowledge Management (CIKM-07), Lisbonne, Portugal, 6-8 novembre 2007, p. 41-50.
- Becker C., DBpedia Extracting structured data from Wikipedia. Presentation à Wikimania, Buenos Aires, Argentine, août 2009.
- 11. Suchanek F M., Automated Construction and Growth of a Large Ontology, Thèse de doctorat, Saarland University, 2008.
- 12. Suchanek F M, Kasneci G., Weikum G., « YAGO: A Large Ontology from Wikipedia and WordNet », Elsevier Journal of Web Semantics, vol. 8, n°3, 2009, p. 203-217.
- 13. Miller G A., WordNet: A Lexical Database for English. Communications of the ACM, vol. 38, n°11, 1995, p 39-41.