Les Bulletins de Santé du Végétal : spécification d'une base d'annotations pour la recherche d'information sémantique en français.

Catherine ROUSSEY¹, Jean-Pierre CHANET¹, Stéphan BERNARD¹

¹ UR TSCF Irstea,

24 avenue des Landais CS 20085 63 178 Aubière prenom.nom@irstea.fr http://www.irstea.fr

Résumé: Dans cet article nous décrivons les différents processus d'annotation envisagés pour annoter un corpus sur les bulletins d'alertes agricoles. Notre but est de publier ces annotations sur le web de données pour permettre à des applications environnementales d'enrichir au besoin nos annotations.

Mots-clés: Annotations sémantiques, annotations spatio-temporelles, recherche d'information sémantique, benchmark, bulletins d'alerte agricole.

1 Introduction

Pour être plus respectueuse de l'environnement, l'agriculture doit modifier ses pratiques. Pour se faire, le plan Ecophyto s'appuie notamment sur le système de surveillance des pratiques agricoles, dont les Bulletins de Santé du Végétal (BSV) sont un des moyens de communication. Ce corpus du domaine agricole contient des informations sur les attaques des bio-agresseurs des cultures par région (par exemple : la DRAAF de la région PACA signale une explosion des attaques de la rouille du blé sur les cultures de blé dur en vallée du Rhône, dans son bulletin du 23 mai 2011).

Nous souhaitons mettre en place plusieurs processus d'annotations spatio-temporelles, notamment pour permettre à des acteurs du domaine agricole de retrouver les BSV répondant à leur besoin, ou à des fins d'étude des évolutions spatio-temporelles des attaques sur les cultures.

Cet article présente un premier état des lieux de nos besoins en annotations. Tout d'abord nous présenterons nos motivations et le corpus des BSV. La section suivante définira notre processus d'annotation, partant de l'extraction des bulletins de santé du végétal et allant jusqu'aux annotations, chacune de ces étapes permettant la collecte d'informations. Nous terminerons par des explications sur la mise en place d'un système de recherche d'information sémantique dédié au monde agricole. Nous souhaitons mettre en place plusieurs expérimentations pour utiliser ce corpus comme benchmark pour la recherche d'informations en français.

2 Motivations

Au fil des dernières décennies, les pratiques agricoles ont fortement évolué sous le jeu de diverses contraintes : enjeux sociétaux et environnementaux, cadre réglementaire, changement climatique... Parallèlement, le rôle des données en agriculture a également fortement évolué : d'abord utilisées à des fins de traçabilité et de sécurité alimentaire, les données, qui sont de plus en plus nombreuses, contribuent maintenant directement au changement des pratiques agricoles par leur aide à une meilleure compréhension de celles-ci. La multiplication des équipements embarqués, des smart-phones, des capteurs aux champs, etc., permet à l'heure actuelle de disposer de grands volumes de données spatio-temporelles (Steinberger et al. 2009). Le prochain enjeu est de rendre ces données disponibles à l'ensemble des acteurs de la filière afin qu'ils puissent les mobiliser dans les outils d'aide à la décision et dans les outils d'analyse (Xie et al 2008; Goumopoulos et al. 2009). Le web de données est une opportunité pour accélérer cette mutualisation des données et, par voie de conséquence, pour faire évolutier les pratiques agricoles.

Afin de pouvoir publier ces données sur le web de données, il convient de structurer les relations entre les différents concepts manipulés par la thématique agriculture : plantes, maladies, ravageurs, pesticides, rotation, ... Un certain nombre de ressources sont disponibles et mobilisables : ontologies de taxons, thésaurus, bases de données, corpus de documents. Mais lorsqu'on s'intéresse à un thème particulier, comme par exemple la protection des cultures, les ressources se font rares. Il faut en effet mobiliser un ensemble de ressources et les relier entre elles. Nous proposons de créer une méthode à même de construire une base de connaissances agrégeant un ensemble de ressources autour d'une thématique. Cela permettra ensuite de publier sur le web de données les données disponibles de manière pertinente, mais également d'annoter les nombreux documents mobilisables pour faire évoluer les pratiques.

Nous avons à notre disposition un corpus de bulletins d'alertes agricoles francophones que nous souhaitons annoter à l'aide d'une base de connaissances sur la protection des cultures. Ainsi, les acteurs du monde agricole pourront rechercher dans ce corpus les bulletins qui les intéressent particulièrement. Dans un second temps nous aimerions

transformer ce corpus en un benchmark pour la recherche d'informations sémantiques francophones, en déployant plusieurs campagnes d'évaluation avec différents acteurs du monde agricole (agriculteurs, agronomes, jardiniers, conseillers agricoles).

3 Les Bulletins de Santé du Végétal

Dans nos travaux, nous nous focalisons sur la protection des cultures. Nous avons à disposition une collection de documents intitulés « Bulletins de Santé du Végétal » (BSV). Nous souhaitons constituer une base archivant les données des attaques des bio-agresseurs sur les cultures (par exemple : attaque de rouille sur une culture de blé dur).

Le Grenelle de l'environnement et le plan Ecophyto ont renforcé les réseaux de surveillance sur les cultures et les pratiques agricoles. Les Bulletins de Santé du Végétal sont une des modalités mises en place par ces réseaux de surveillance.

Le Bulletin de Santé du Végétal (BSV) est un document d'information technique et réglementaire, rédigé sous la responsabilité d'un représentant régional du ministère de l'agriculture. Ce représentant peut être par exemple la Chambre Régionale d'Agriculture ou bien la Direction Régionale de l'Alimentation, de l'Agriculture et de la Forêt (DRAAF). Ce représentant doit mettre à disposition ses bulletins sur son site internet afin d'en permettre un accès public. La conséquence est que les BSV sont répartis sur différents sites web (un par région). À notre connaissance, il n'existe pas encore de système donnant un accès uniforme à l'ensemble des BSV.

Les BSV sont rédigés en collaboration avec de nombreux partenaires impliqués dans la protection des cultures. La liste des auteurs des BSV varie en fonction de la région et de la filière agricole. Par conséquent leur contenu et leur présentation ne sont pas uniformes et varient en fonction des auteurs.

Les BSV diffusent des informations relatives à la situation sanitaire des principales productions végétales de la région et proposent une évaluation des risques encourus pour les cultures. Des données générales concernant les stratégies de lutte (notes nationales, ...) ou sur la réglementation peuvent figurer également dans les BSV.

Selon l'actualité sanitaire et/ou la culture, le rythme de parution des BSV est variable, allant d'une parution hebdomadaire à mensuelle.

Les BSV sont une synthèse des observations effectuées sur les cultures. Il existe des bases de données d'observations mais la rédaction des BSV oblige leurs auteurs à décider si une observation est un phénomène unique non représentatif ou un phénomène important représentatif d'une réalité. Les BSV ne sont pas une agrégation



automatique de données mesurées mais bien une synthèse humaine des jugements sur des observations.

FIGURE 1 – Exemple de BSV de la région Midi-Pyrénées pour la filière grande culture

Nous avons récupéré les BSV de l'année 2011 de 19 régions. En moyenne une région publie plus d'une centaine de BSV par an. Au total

nous avons 2825 BSV pour l'année 2011. Dans un premier temps nous limiterons notre analyse aux BSV de la région Bourgogne concernées par la filière « grande culture », c'est à dire 37 BSV.

4 Processus d'annotation des BSV

Ce processus d'annotation de notre collection de bulletins est constitué de trois phases, chacune permettant l'extraction d'informations, de plus en plus fines. La première phase, qui consiste en la récupération et l'extraction des fichiers bruts, ne nécessitera pas d'analyse du contenu des BSV. Il permettra néanmoins d'identifier la région, la date et la filière agricole concernée. La seconde phase est un pré-traitement qui permettra de récupérer les noms des cultures et de leurs agresseurs dans les textes. Elle aura pour résultat une première série d'observations spatio-temporelles des attaques des agresseurs sur les cultures. La dernière phase sera l'annotation en elle-même, et visera à récupérer les niveaux de risques liés aux attaques des agresseurs dans les cultures. Ces différentes phases du processus sont décrites plus précisément dans les sections suivantes.

4.1 Extraction brute

4.1.1 Principe

Les BSV sont disponibles sur les sites des chambres d'agricultures ou des DRAAFT. Les pages contenant les liens permettant le téléchargement des fichiers pdf contenant les BSV nous donnent déjà un certain nombre d'informations :

- La région : elle est indiquée par le nom du site web
- La filière agricole concernée : le site a généralement une page par filière, donc le nom de la page web nous permet de récupérer cette information
- Le numéro du BSV : le nom du fichier téléchargé contient souvent le numéro du BSV.
- La date de parution : le nom du fichier téléchargé contient souvent cette date.

Ce premier niveau d'annotations a été réalisé en analysant les différentes pages web contenant les liens vers les fichiers pdf.

4.1.2 Problèmes rencontrés

Il est important de constater que les listes des filières agricoles disponibles ne sont pas normalisées d'une région à une autre. En effet, tout dépend des productions agricoles de la région. Certaines régions vont

regrouper plusieurs filières. Par exemple, la Haute-Normandie a une filière « arboriculture et petits fruits ». D'autres régions ont au contraire une production très spécialisée et ne vont indiquer que la production qui les intéresse : la Bourgogne, par exemple, a une filière « cassis » sans avoir de filière « petit fruit ». Il est donc nécessaire de normaliser les noms des filières entre les régions, et de constituer une classification homogène des filières de productions agricoles en France. Une classification des filières agricoles françaises est déjà disponible sur le site français de Wikipedia¹. Cette classification a été enrichie manuellement pour couvrir l'ensemble des noms de filières utilisées dans les 20 régions.

Suivant les cas, il est possible qu'un BSV soit associé à plusieurs filières.

4.2 Pré-traitement

4.2.3 Principe

Ce second niveau d'analyse, au contraire du précédent, a pour but de travailler sur le contenu textuel des BSV. Nous souhaitons récupérer dans le texte, le nom des plantes cultivées et le nom de leurs agresseurs.

Dans l'exemple de la **Fig 1**, les noms des cultures sont présents dans les titres des sections (maïs), et les agresseurs parmi les sous-sections (sésamie, pyrale, ...). La structure logique du document nous donne l'indication que la sésamie et la pyrale sont des agresseurs du maïs. Cette régularité éditoriale est vérifiée sur l'ensemble des BSV de toutes les régions. Ainsi la reconnaissance des noms des organismes vivants dans les titres des sections et leur organisation logique dans le texte nous permet de produire nos premières annotations : attaque de la culture maïs par l'agresseur pyrale dans la région Midi-Pyrénées à la date du 15 juin 2011.

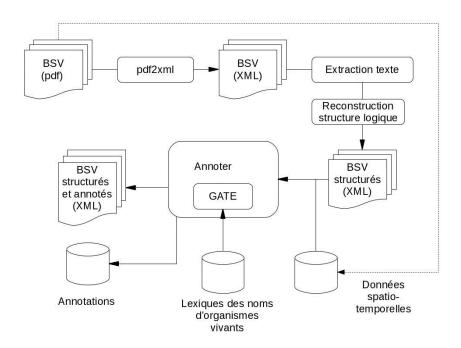
La Fig 2 présente le processus de pré-traitement, puis le processus d'annotation :

Dans un premier temps il est nécessaire de transformer les fichiers au format PDF en un format qui permet une lecture plus aisée de la structure du document. Le logiciel pdf2xml (Dejean Giguet 2012) nous offre une sortie XML contenant des balises représentant l'organisation physique du document et sa mise en page. Chaque mot est encadré par une balise ayant des attributs de mise en forme et de position dans la page. A partir de ces fichiers XML, nous récupérons l'ensemble des contenus textuels.

Ensuite, nous reconstruisons automatiquement la structure logique des documents, en rassemblant les mots. Le but est d'identifier les sections, leur titre et leurs paragraphes, ainsi que leur inclusion logique (section et sous section). Cette structure logique sera décrite dans des fichiers XML,

http://fr.wikipedia.org/wiki/Classement_en_France_des_cultures_par_groupes_d'usage

et seront les entrées du processus d'annotation. On leur associera les informations spatio-temporelles recueillies lors de l'extraction des



fichiers bruts.

Cette phase de pré-traitement est en cours d'élaboration et a été testée sur les grandes cultures dans quatre régions.

FIGURE 2 – *Processus d'annotation*.

4.2.4 Problèmes rencontrés

La mise en page des BSV n'est pas homogène : certains utilisent par exemple une mise en page en plusieurs colonnes, d'autres ont une mise en page sur une seule colonne. La détection des colonnes complexifie le processus de reconstruction de la structure logique, surtout lorsque certains effets de mise en page, tels que des cadres chevauchant plusieurs colonnes, empêchent d'établir correctement la frontière entre colonnes.

La mise en page des BSV ne varie pas seulement d'une région à l'autre, mais aussi d'une culture à l'autre, les auteurs des bulletins semblant peu contraints sur cet aspect. Cette diversité rend difficile la création d'une structure logique uniforme pour l'ensemble des BSV. Toutefois, l'association des tailles de caractères et de leurs attributs (gras, italique) et d'une description générale des structures des différents BSV

permet d'obtenir, à quelques exceptions près, les informations nécessaires à la phase d'annotation.

4.3 Annotations

4.3.5 Principe

L'annotation des BSV est composée de deux étapes :

- La première étape, appelée simplement « annotation », consiste à reconnaître les noms des organismes vivants dans les titres des sections, à partir d'un lexique.
- La seconde étape, nommée annotation fine, vise à estimer, à partir du contenu de la section, si l'agresseur en question est cité pour avoir été observé, ou au contraire parce qu'aucune attaque n'a été constatée, ou encore pour inciter à prévenir une attaque.

Pour ces deux étapes, la plateforme GATE sera utilisée (Cunnigham et al. 2011).

4.3.6 L'annotation « simple »

4.3.6.1 Principe

Cette première phase d'annotation utilisera en entrée un lexique précédemment défini. Le lexique sera composé des noms de plantes cultivées en France ainsi que les noms de leurs agresseurs (champignons, plantes, insectes, animaux, ...). Ces lexiques seront dérivés d'une base de connaissances construite à partir de ressources disponible sur le LOD.

La relation entre une plante cultivée et son agresseur sera dérivée automatiquement de la structure logique du document. L'inclusion logique entre sections implique la présence de l'agresseur sur la culture.

4.3.6.2 Problèmes rencontrés

Pour mettre en place ce processus d'annotations, nous avons besoin de construire des lexiques d'organismes vivants et de les classer en plantes cultivées (culture) et en agresseur des cultures (organisme vivant nuisant au développement d'une plante cultivée). Ces lexiques seront dérivés d'une ontologie des organismes vivants capable de classer automatiquement un organisme en plantes cultivées ou en agresseurs d'une culture. Contrairement à nos attentes, catégoriser une plante en plante cultivée (culture) ou en agresseur n'est pas évident :

1 Une plante peut être associée à différentes filières agricoles. La filière agricole indique l'usage de sa production : huile, céréale panifiable, fourrage, ornementale etc... et donc une même plante peut être utilisée pour différentes cultures.

- 2 De plus, sa culture est contextuelle. En effet, certaines plantes sont plus adaptées à un climat qu'à un autre; les usages alimentaires du pays peuvent aussi entrer en compte. Par exemple le riz est consommé partout en France mais il s'agit principalement de riz importé. Les principaux pays producteurs de riz sont la Thaïlande, le Pakistan, les USA et la Chine. En France métropolitaine seule la région PACA produit du riz. La définition d'une culture (d'une filière agricole) est dépendante du pays et donc elle ne peut pas être généralisée.
- 3 Dernier point, une plante peut à la fois être une plante cultivée ou un agresseur d'une autre culture. Par exemple, sur une parcelle agricole cultivée pour du blé, il peut persister une ancienne culture qui va gêner le développement de la culture en cours. Ainsi d'une année à une autre, la même plante peut être catégorisée sous forme de culture ou d'agresseur.

Pour identifier les plantes cultivées, nous allons nous baser sur la classification des filières agricoles précédemment définies dans le processus d'annotations brutes. Dans notre ontologie, les organismes vivants seront décrits par leurs caractéristiques agronomiques (plantes, champignons, animaux etc.). Cette description est générique, c'est à dire commune quel que soit le pays concerné ou le domaine étudié (agriculture, botanique, épidémiologie). Cette description sera ensuite enrichie par l'usage de la plante en agriculture en indiquant sa filière agricole. Ainsi, un raisonneur pourra automatiquement découvrir les plantes cultivées en France. Dans un second temps, nous allons nous intéresser aux agresseurs des cultures les plus connus qui apparaissent dans des listes d'agresseurs publiées. La notion d'agresseur étant elle aussi contextuelle il est nécessaire de la dériver d'une observation d'agression. Nous allons, de la même façon que précédemment, enrichir la description d'un organisme par ses agressions connues, pour dériver les agresseurs des cultures. De la même manière nous pourrons dériver les auxiliaires des cultures, c'est-à-dire les agresseurs des agresseurs des cultures.

Cette ontologie sera enrichie au cours du temps pour tenir compte des différents noms régionaux que peut avoir un organisme vivant et aussi de l'apparition de nouveaux organismes dans différents pays. Par exemple les changements climatiques permettent à des organismes de se développer dans des lieux où préalablement ils n'avaient pas les moyens de subsister. Les nouveaux moyens de transports et routes commerciales permettent aussi des migrations d'organismes vivants.

4.3.7 L'annotation fine

4.3.7.3 Principe

Dans l'annotation précédente des BSV nous avons fait l'hypothèse que toute apparition dans le texte d'un agresseur indique qu'il y a eu une observation de l'agression d'une culture par cet agresseur. Cette hypothèse est fausse dans certains cas. En effet, il arrive que la section sur l'agresseur indique qu'aucune observation de cet agresseur sur la culture n'a été constatée. Il est possible aussi que le texte indique que l'agresseur n'est pas assez présent sur la culture pour entraîner un risque.

Nous avons donc besoin d'extraire des textes un ensemble d'informations précises comme :

- Le stade de développement de la plante lors de l'observation. Cette information permet une estimation du risque. En effet, selon le stade de développement de la plante, l'apparition d'un organisme extérieur peut nuire à la culture ou avoir un impact limité voir inexistant sur le développement de la culture. Ce stade de développement est aussi nécessaire pour connaître le moyen de lutte adéquat. Les stades de développement des plantes sont publiés dans des listes et nous pourrons, à l'aide d'un lexique approprié, extraire ces informations.
- Le niveau de risque de l'agression. Ce niveau est dépendant du stade de développement de la culture et du nombre d'agresseurs présents dans la culture. Les niveaux de risques sont aussi publiés dans des listes. Nous pourrons donc extraire ces informations à l'aide d'un lexique.
- Le nombre de parcelles agricoles impliquées où une attaque a été constatée. Ce nombre peut aussi être exprimé en pourcentage.

Pour extraire ce type d'information nous avons donc besoin d'une analyse des textes plus fine, avec des processus de traitement automatique du langage naturel. Nous allons mettre en place des règles linguistiques pour extraire des hypothèses qui devront être validées manuellement ensuite.

La **Fig 3** présente le processus d'annotations fines. Nous allons, comme précédemment, utiliser la plateforme Gate. Cette plateforme utilisera plusieurs lexiques dérivés automatiquement de notre ontologie. Le but des lexiques sera de découvrir les termes représentant les stades de développement des cultures et les niveaux de risques. Ensuite nous appliquerons des règles linguistiques pour extraire l'observation d'une attaque d'une culture avec son niveau de risque et le stade de développement de la plante, à partir du contenu de la section.

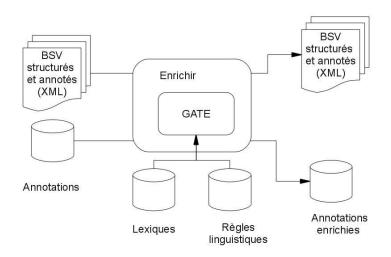


FIGURE 3 – *Processus d'annotations fines*.

4.3.7.4 Problèmes rencontrés

Nous voulons atteindre plusieurs buts dans cette annotation. Dans un premier temps, nous voulons découvrir s'il y a eu effectivement une observation d'une attaque d'un agresseur sur une culture. Ensuite nous voulons enrichir cette observation en indiquant le niveau de risque et le stade de développement de la plante. Ces informations ne sont pas forcement indiquées dans le texte des BSV. Parfois le BSV rappelle juste dans un tableau les niveaux de risque en fonction des stades de développement, sans donner aucune indication sur l'observation réalisée. Donc nous devrons prendre en compte les absences d'observations. Les résultats du processus d'annotations fines devront être validés manuellement pour compléter au besoin les imperfections de ce processus automatique.

5 Système d'interrogation des BSV

Au fur et à mesure, l'ensemble de nos annotations sera mis à disposition sur le web par le biais d'un SPARQL end point. Pour faciliter l'interrogation SPARQL de ces annotations, nous intégrerons, au dessus

de SPARQL end point, le système d'interrogation en langage naturel développé par l'IRIT intitulé SWIP (Pradel et al, 2012). Ce système permet aux utilisateurs de requêter un SPARQL end point à l'aide d'une requête sous forme d'une question en langage naturel, Il se base sur des patrons de requêtes représentatifs du domaine et sur des phrases en langage naturel pour proposer à l'utilisateur plusieurs requêtes SPARQL possibles.

Il est à noter que nous ne sommes pas dépositaires des BSV. Nous avons connaissance d'un autre projet d'annotations des BSV dont l'INRA est l'un des membres partenaires : Le projet Vespa. Ce projet devrait mettre en ligne les versions électroniques des documents. Donc nous ne mettrons en ligne que nos annotations. Nous établirons un lien entre nos annotations et les versions des BSV mises en lignes dans le projet Vespa.

6 Conclusion et perspectives

Dans cet article nous décrivons les différents processus d'annotation envisagés pour annoter un corpus sur les bulletins d'alertes agricoles. Notre but est de publier ces annotations sur le web de données pour permettre à des applications environnementales d'enrichir au besoin nos annotations. Nous souhaitons utiliser ce corpus de bulletins pour mettre en place une première campagne d'évaluation de systèmes de recherche d'information sémantique en français.

Dans le but de développer notre benchmark de recherche sémantique en français, nous souhaitons mettre en place plusieurs expérimentations de recherche d'information sur les BSV. Nous avons en tête d'utiliser plusieurs groupes d'utilisateurs :

- des experts en agronomie, notamment de l'INRA,
- des responsables d'exploitations issus des établissements d'enseignement agricole,
- des internautes agriculteurs identifiés dans les réseaux sociaux agricoles.

Ainsi il sera aussi possible d'effectuer des recherches en fonction du profil de l'utilisateur

Références

CUNNINGHAM H., MAYNARD D., BONTCHEVA K. (2011) Text Processing with GATE (Version 6) University of Sheffield Department of Computer Science. 15 April 2011. ISBN 0956599311

DEJEAN H., GIGUET. (2012) pdf2xml, available at http://sourceforge.net/projects/pdf2xml/last update octobre 2012.

- GOUMOPOULOS, C., KAMEAS, A.D., CASSELLS, A. (2009). An ontology-driven system architecture for precision agriculture applications. International Journal of Metadata, Semantics and Ontologies 4, p 72–84.
- PRADEL, C. HAEMMERLE, O. HERNANDEZ, N. (2012) Des patrons modulaires de requêtes SPARQL dans le système SWIP. Dans : Journées Francophones d'Ingénierie des Connaissances (IC 2012), Paris, 27/06/2012-29/06/2012, juin 2012, p 385-400.
- STEINBERGER, G., ROTHMUND, M. & AUERNHAMMER, H. (2009) Mobile farm equipment as a data source in an agricultural service architecture. Computers and electronics in agriculture, 65(2), 2009, p.238–246.
- XIE, N., WANG, W., YANG, Y. (2008) Ontology-based agricultural knowledge acquisition and application, in: Computer And Computing Technologies In Agriculture, Volume I. Springer, 2008, p. 349–357.